

Trabajo Final de Máster

Entrega Final

Cada estudiante deberá entregar **2 proyectos**:

1. **Proyecto 1 (obligatorio): “Modelización Predictiva y Métricas de Negocio”**
2. **Proyecto 2 (a elegir): “Resumen multimodal de investigación” o “Asistente RAG multiformato”**

Los proyectos deben estar subidos en el **GitHub personal** de cada alumno, cada uno en su propio repositorio. El enlace a cada repositorio deberá ser compartido a través del **campus virtual** dentro del plazo de entrega.

Cada repositorio deberá incluir de forma obligatoria:

- El código fuente completo del proyecto (scripts, notebooks, módulos, etc.).
- Los resultados obtenidos (outputs, métricas, visualizaciones, ejemplos, etc.).
- Las visualizaciones realizadas con cualquier herramienta.
- Un archivo **Markdown (README)** explicativo que **narre el proyecto de forma estructurada y coherente**, integrando de manera natural las respuestas a las preguntas planteadas en el enunciado. No se trata de copiar las preguntas y responderlas una por una, sino de **construir un relato con hilo conductor** que explique el proceso completo: desde la definición del problema, la elección de datos y modelos, hasta la interpretación de resultados y conclusiones.

El objetivo general del TFM es **demostrar la capacidad de aplicar el conocimiento aprendido en un entorno realista**, integrando la investigación, el desarrollo técnico y la generación de valor a partir de datos.

Los enunciados de los proyectos están diseñados para permitir **libertad de exploración**: puedes enfocarte en distintos caminos técnicos, herramientas o hipótesis, siempre que **cumplas los requisitos mínimos y respondas las preguntas planteadas**.

A partir de esa base, se valorará positivamente cualquier ampliación técnica, reflexión adicional o propuesta original.

Evaluación del TFM

La nota final del TFM se calculará ponderando los dos proyectos:

- **Proyecto 1 (Modelización Predictiva y Métricas de Negocio): 60 % de la nota final**
- **Proyecto 2 (Resumen multimodal o Asistente RAG multiformato): 40 % de la nota final**

Cada proyecto se evaluará según las siguientes 5 categorías:

1. **Investigación y justificación técnica (3 puntos):** nivel de análisis y reflexión, elección argumentada de herramientas, modelos y técnicas.
2. **Resultados y visualizaciones (2.5 puntos):** calidad y utilidad de los resultados y visualizaciones.
3. **Calidad del código y estructura del repositorio (2 puntos):** claridad, modularidad y documentación.
4. **Innovación, creatividad y originalidad (1.5 puntos):** enfoques nuevos o mejorados.
5. **Documentación y storytelling (1 punto):** calidad narrativa, claridad y coherencia del Markdown.

Puntuación total por proyecto: 10 puntos.

La **nota final del TFM** se calculará aplicando la ponderación 60/40 entre los dos proyectos.

Ejemplo de evaluación del TFM:

- **Proyecto 1: Modelización Predictiva y Métricas de Negocio**
 - Investigación y justificación técnica: 2.7 / 3
 - Resultados y visualizaciones: 2.3 / 2.5
 - Código y estructura: 1.8 / 2
 - Innovación: 1.2 / 1.5
 - Documentación: 0.9 / 1

Total Proyecto 1: 8.9 / 10

- **Proyecto 2: Asistente RAG multiformato**

- Investigación y justificación técnica: 2.5 / 3
- Resultados y visualizaciones: 2.1 / 2.5
- Código y estructura: 1.7 / 2
- Innovación: 1.3 / 1.5
- Documentación: 0.9 / 1

Total Proyecto 2: 8.5 / 10

Nota final del TFM = $(8.9 \times 0.6) + (8.5 \times 0.4) = 8.74 / 10$

Importante

Un buen Data Scientist no solo ejecuta, sino que **analiza, investiga y justifica sus decisiones**.

Se valorará la capacidad de **comparar alternativas, optimizar recursos y comunicar el valor de las soluciones** con rigor técnico y orientación a negocio.

Requisitos del Markdown de cada proyecto

En el archivo README o Markdown principal de cada proyecto, deberás incluir una explicación **clara, estructurada y completa** del trabajo realizado.

No se trata de responder preguntas de forma aislada, sino de construir una **narrativa coherente** que justifique las decisiones y muestre el proceso completo.

Este documento debe:

- Describir el flujo de trabajo seguido y las decisiones técnicas tomadas.
- Integrar naturalmente las respuestas a las preguntas planteadas en el proyecto.
- Incluir ejemplos, métricas y visualizaciones relevantes.
- Explicar con claridad las dificultades encontradas y cómo se resolvieron.
- Incluir un esquema visual o textual del sistema completo (datos, modelado, evaluación, resultados).

 **Toda aportación adicional —reflexión, mejora técnica, ampliación experimental o integración de herramientas— será valorada positivamente. No**

se valorará la complejidad del modelo, sino la claridad del razonamiento y la capacidad de generar valor con los datos.

Proyecto 1: "Modelización Predictiva y Métricas de Negocio"

Objetivo

Desarrolla un proyecto **end-to-end de Machine Learning** donde definas un **objetivo de negocio claro**, construyas un modelo predictivo y traduzcas sus resultados a **métricas que aporten valor empresarial**.

El alumno podrá elegir libremente el tipo de problema y los datos, siempre que cumpla los siguientes requisitos:

- El problema debe pertenecer a una de las siguientes categorías:
 - **Regresión**: predicción de valores numéricos (ventas, precios, tiempos, ingresos...).
 - **Clasificación**: predicción de categorías (churn, fraude, contratación, respuesta a campañas...).
 - **Series temporales**: predicción basada en tiempo (demanda, visitas, consumo, producción...).

A lo largo del proyecto se deberá demostrar la **capacidad para recorrer todas las fases de un pipeline de Machine Learning**, desde la definición del problema hasta la interpretación final del modelo y la explicación de su posible despliegue:

1. **Definir el objetivo de negocio y las preguntas que el modelo debe responder.**
2. **Explorar, limpiar y preparar** los datos.
3. **Entrenar, validar y comparar** modelos predictivos.
4. Aplicar **técnicas de explicabilidad** (SHAP, LIME, feature importance, PDP, etc.).
5. **Traducir las métricas técnicas y explicativas del modelo a métricas de negocio**, mostrando el impacto real o potencial del modelo.
6. **Explicar cómo llevarías el modelo a producción** (solo de forma conceptual, sin implementarlo).

 Ejemplos de proyectos posibles:**1. Predicción de abandono de clientes (churn prediction)**

- *Enfoque:* Estimar la probabilidad de baja de un cliente.
- *Datos:* Histórico de comportamiento y uso de productos.
- *Métricas de negocio:* Valor económico de los clientes retenidos al aplicar el modelo al top 10 % de riesgo.

2. Estimación de demanda o ventas futuras

- *Enfoque:* Predecir el volumen de ventas de un producto o categoría.
- *Datos:* Histórico de ventas, promociones, estacionalidad y precios.
- *Métricas de negocio:* Reducción del error medio de previsión y del sobrestock, mejorando la eficiencia del inventario.

3. Clasificación de leads con mayor probabilidad de compra

- *Enfoque:* Identificar los leads más propensos a convertirse en clientes.
- *Datos:* Información de campañas, interacciones y características del lead.
- *Métricas de negocio:* Revenue potencial del top N % de leads predichos como positivos.

 Entregable

Un repositorio de GitHub con:

- Código completo (scripts o notebooks) que reproduzca todo el flujo del proyecto.
- Datos utilizados o enlace a la fuente pública.
- Resultados, métricas y visualizaciones.
- Un archivo **Markdown (README.md)** explicativo que documente el proceso completo, las decisiones tomadas y las métricas técnicas y de negocio.
- Un esquema visual o textual del sistema desarrollado (pipeline de datos, modelado, evaluación y comunicación de resultados).
- Una **sección final** donde **explique conceptualmente cómo se llevaría el modelo a producción**, indicando:
 - ¿Qué parte del flujo se ejecutaría (API, proceso batch, dashboard, etc.)?

- Cada cuánto se reentrenaría el modelo.
- Cómo se monitorizaría el rendimiento y el *data drift*.
- Cómo se actualizaría el modelo o las *features* ante cambios en los datos o el entorno.

(No es necesario implementar esta parte, solo describir cómo se haría en un escenario real. No se evaluará la implementación técnica del despliegue, sólo la comprensión conceptual del proceso.)

Preguntas a responder

- ¿Cuál es el objetivo de negocio que intentas resolver? ¿Qué impacto tendría si el modelo funciona correctamente?
- ¿Qué tipo de variable predices (numérica, categórica, temporal) y por qué elegiste ese enfoque?
- ¿Qué fuentes de datos utilizaste? ¿Cómo limpiaste y transformaste las variables?
- ¿Qué modelos probaste y cómo justificas su elección?
- ¿Qué métricas técnicas usaste para evaluar el rendimiento (MAE, RMSE, F1, ROC-AUC, etc.) y por qué son adecuadas?
- ¿Qué técnicas de explicabilidad aplicaste? ¿Qué información te aportaron sobre el modelo?
- ¿Qué variables influyen más en las predicciones y cómo interpretas su efecto?
¿Qué métricas de negocio definiste (por ejemplo, revenue potencial, ahorro, reducción de error logístico, tasa de retención)?
- ¿Qué resultados obtuviste al traducir el modelo a indicadores empresariales?
- **¿Cómo llevarías el modelo a producción (de forma conceptual)?**
 - ¿Sería un modelo en tiempo real o por lotes?
 - ¿Cada cuánto lo reentrenarías y con qué criterio?
 - ¿Cómo monitorizarías su rendimiento y detectarías *data drift*?
 - Si descubres una nueva *feature* o mejoras el modelo, ¿cómo lo actualizarías o versionarías?
 - ¿Qué herramientas o estructura utilizarías para desplegarlo en un entorno real (API, Docker, pipeline, dashboard)?
- ¿Qué conclusiones extraes y cómo podría mejorarse el sistema en una versión futura?

Proyecto 2: "Resumen multimodal de investigación"

Objetivo

Investiga un tema relevante y de interés mediante la extracción de información de distintas fuentes: Debe ser capaz de extraer **2 tipos de documentos**:

1. **Texto escrito**: artículos de blogs, prensa, papers científicos, informes, etc., obtenidos de páginas web mediante scraping o APIs.
2. **Transcripción de audio/vídeo**: contenido hablado procedente de plataformas como YouTube, TikTok o Spotify (transcripciones de vídeos o podcasts).

A partir de esta información extraída, se debe construir un **resumen global** que sintetice los puntos clave y genere una visión general del tema. Además, se deberán crear **visualizaciones** que aporten valor y ayuden a descubrir patrones, relaciones o insights relevantes en el contenido analizado. Para extraer insights, puedes utilizar cualquier método de Machine Learning (por ejemplo, clustering, análisis de sentimiento, clasificación, etc.) o también apoyarte en modelos LLM. Finalmente, presenta **2 visualizaciones** que permitan descubrir y comunicar esos insights de forma clara y visual. Estas visualizaciones pueden realizarse con cualquier herramienta de tu elección. Puedes optar por programarlas directamente en el notebook usando librerías como matplotlib, seaborn, plotly o similares. También puedes utilizar plataformas de visualización profesional como Tableau, PowerBI o Looker Studio para dashboards más elaborados. Incluso puedes montar una pequeña aplicación interactiva con Streamlit, Gradio o herramientas frontend sencillas para mostrar los resultados de forma accesible y atractiva.

Ejemplos de temas posibles:

1. Inteligencia Artificial en la educación

- **Enfoque**: Comparar cómo se está utilizando la IA en distintos niveles educativos (primaria, secundaria, universidad, formación online).
- **Fuentes**: Artículos de medios tecnológicos (ej. Xataka, Wired), blogs educativos, y vídeos de conferencias TED o entrevistas con docentes.
- **Visualizaciones**:
 - Mapa de calor con herramientas de IA mencionadas por tipo de educación.
 - Análisis de sentimiento de opiniones docentes vs. alumnos sobre la IA.

2. Organizador de viajes inteligente

- **Enfoque:** Crear una herramienta de investigación y resumen de información turística sobre un destino concreto (por ejemplo, "Tokio", "Islas Canarias", "Nueva York").
 - **Fuentes:** Blogs de viajes, páginas de recomendaciones, foros, vídeos de YouTube o TikTok de creadores que visitan el destino.
 - **Visualizaciones:**
 - Mapa con los puntos turísticos más mencionados o recomendados.
 - Wordcloud con términos frecuentes sobre gastronomía, cultura o actividades populares.
-

Entregable

Un repositorio de GitHub con:

- Código para la recolección de artículos, blogs, páginas web, audios, vídeos...
 - Procesado de los datos, limpieza y unificación de los textos
 - Generación de resumen e insights con LLM (open-source o API) y/o algoritmos de Machine Learning
 - Dos visualizaciones basadas en el contenido extraído
 - Ejemplo de ejecución del proyecto
 - Markdown del repositorio con la explicación del proyecto respondiendo a las preguntas. Además, deberá incluir un esquema visual o textual del sistema completo creado, identificando cada uno de los módulos desarrollados (extracción, procesamiento, modelado, generación de insights y visualización), cómo se relacionan entre sí y qué herramientas o técnicas se han utilizado en cada parte.
-

Preguntas a responder

- ¿Qué técnica empleaste para extraer la información de las fuentes? ¿Usaste APIs, web scraping, un agente conversacional o alguna herramienta específica? ¿Qué ventajas y limitaciones encontraste con cada método?
- ¿Cómo procesaste y limpiaste los datos?
- ¿Cómo generaste el resumen y los insights? ¿Probaste distintos prompts o enfoques?
- ¿Qué muestran tus visualizaciones y por qué son relevantes?

- Crea un esquema visual o textual del sistema que has construido. Describe brevemente los distintos componentes involucrados (extracción, procesamiento, modelado, generación de insights, visualización) y cómo interactúan entre sí.
- ¿Qué mejorarías si tuvieras más tiempo o recursos?

Proyecto 3: *"Asistente RAG multiformato"*

Objetivo

Construye un asistente inteligente basado en Retrieval-Augmented Generation (RAG) capaz de **responder preguntas sobre una base documental compuesta por 5 formatos distintos**: archivos en cualquier formato como PDF, DOCX, CSV, JSON, TXT, Markdown, HTML o cualquier otro que consideres útil para tu proyecto (por ejemplo, XML, YAML, logs, formatos propietarios exportables, etc.).

El flujo del proyecto consta de dos fases:

1. Crear un sistema básico RAG que procese los 5 formatos.
2. Investigar y proponer una **técnica de mejora** que aumente la calidad de las respuestas (mejor chunking, re-ranking, multi-hop, prompt tuning, etc.).

Ejemplos de dominios posibles:

- Manuales técnicos de productos
- Regulaciones y leyes ambientales
- Documentación interna de una empresa ficticia (por ejemplo, políticas internas, instrucciones, emails)
- Archivos académicos o apuntes personales sobre distintas materias
- Notas de reuniones, actas, informes, hojas de cálculo con KPIs o presupuestos
- Contenido propio de plataformas personales como Notion, Evernote, Google Keep o cualquier sistema de notas personales, incluyendo la posibilidad de crear un asistente conectado a tu Google Drive que acceda a tu cuenta (mediante permisos controlados), procese documentos almacenados y permita consultar la información contenida en ellos

Entregable

Un repositorio de GitHub con:

- Código de ingesta para cada uno de los 5 formatos
- Proceso de generación de embeddings y vector store (FAISS, Chroma, etc.)
- Asistente básico con un LLM + retrieval
- Versión mejorada con tu técnica propuesta

- Ejemplo de ejecución del proyecto
 - Markdown del repositorio con la explicación del proyecto respondiendo a las preguntas. Además, deberá incluir un esquema visual o textual del sistema completo creado, identificando cada uno de los módulos desarrollados (extracción, procesamiento, generación de embeddings, recuperación de contexto, razonamiento/generación final de respuestas, visualización de resultados o flujos si aplica), cómo se relacionan entre sí y qué herramientas o técnicas se han utilizado en cada parte.
-

Preguntas a responder

- ¿Qué documentos y formatos has utilizado?
- ¿Cómo has dividido y preparado los datos para el sistema?
- ¿Qué modelo y vector DB has usado y por qué?
- ¿Cómo evalúas la calidad de las respuestas?
- ¿Cuál fue tu propuesta de mejora y cuál fue su impacto?
- ¿Qué aprendiste sobre los sistemas RAG y sus limitaciones?