



EXPLICACIÓN DE MODELOS

BIG school



**Explicación de
modelos**

ÍNDICE

Introducción a la explicabilidad

Explicabilidad global

Explicabilidad local

Explicabilidad agrupada

Explicabilidad + GenAI



Introducción a la explicabilidad

BIG school

BIGSEIO

GENERAMOS
NEGOCIO




Definición

BIG school

Definición

Explicabilidad o interpretabilidad: La capacidad de entender cómo un modelo llega a una predicción específica o a un patrón general.


Muchos modelos se consideran cajas negras ya que, debido a la complejidad de los algoritmos y a su implementación, las predicciones que producen no son interpretable con facilidad



Definición



Trade off entre interpretabilidad y precisión

Por norma general, los algoritmos más simples son los que ofrecen una mejor explicabilidad, ya que los mecanismos por los que se rigen son mucho más comprensibles para una mente humana



Definición


Trade off entre interpretabilidad y precisión



Un claro ejemplo es la explicabilidad inherente que se puede obtener de un árbol de decisión vs una compleja red neuronal

Definición

Trade off entre interpretabilidad y precisión



Importancia de la explicabilidad

BIG school

BIGSEIO

GENERAMOS
NEGOCIO

Importancia de la explicabilidad

Hay 4 grupos para los cuales la explicabilidad es de gran interés:

1.Data Scientists



2. Entidades reguladoras



3.Stakeholders





4.Ventas



Importancia de la explicabilidad

1.Data Scientists



El análisis de las distintas técnicas de explicabilidad permite hacer "sanity-checks" a los modelos en busca de posibles errores, como por ejemplo: data leakage

Importancia de la explicabilidad

2. Entidades reguladoras

En ciertos ámbitos, como el análisis de riesgos para la concesión de préstamos, hay múltiples regulaciones y se exige que cada predicción que se hace (rechazo o concesión) pueda ser justificada de una manera clara y comprensible

Consumer Financial Protection Bureau



CFPB Issues Guidance on Credit Denials by Lenders Using Artificial Intelligence

Consumers must receive accurate and specific reasons for credit denials

SEP 19, 2023

Banco de España




ACCURACY OF EXPLANATIONS
OF MACHINE LEARNING MODELS
FOR CREDIT DECISIONS

Importancia de la explicabilidad

3.Stakeholders

Cuando se presentan los resultados a los stakeholders (normalmente, no técnicos) es de vital importancia que los resultados del modelo sean explicables e interpretables para que puedan comprender el funcionamiento y la utilidad del proyecto.



Importancia de la explicabilidad

4. Ventas

Para que los comerciales vendan de manera más eficiente y con más confianza en el modelo es esencial ser capaces de explicar lo que hay detrás de las predicciones que les estamos sirviendo



Acción del día	Venta de teléfonos de alta gama
Listad de clientes a llamar	A, J, X, R



Acción: Venta de teléfono de alta gama

Tipo de cliente: Amante de la tecnología

Justificación: Este cliente es probable que compre un teléfono de alta gama ya que tiene un alto saldo en cuenta (10.500€), ha realizado compras de otros teléfonos anteriormente y usa nuestra aplicación con frecuencia (48 logins últimos 2 meses)






Tipologías: global, local y agrupada

BIG school

Tipologías: global, local y agrupada


Existen principalmente tres tipos de explicabilidad de modelos, según su granularidad:

Global




Granularidad mínima

Local



Granularidad máxima

Colectiva




Granularidad intermedia

Tipologías: global, local y agrupada

EXPLICABILIDAD GLOBAL

- **Global:** se centra en ilustrar las características generales del modelo, dando una visión general de lo que sucede
 - + Visión a alto nivel del comportamiento del modelo
 - ✗ No es representativo de todos los individuos
 - ✗ No permite tomar decisiones a nivel observación




Se obtiene un perfil de la persona promedio es propensa (compra de producto, concesión de préstamo, fuga de entidad, etc)

Tipologías: global, local y agrupada

EXPLICABILIDAD LOCAL

- **Local:** baja a nivel de observación, dando motivos concretos del comportamiento del modelo para cada una de las observaciones

- + Explicación individualizada, nivel de detalle máximo
- + Permite agregar a nivel Global
- ✗ Difícil aplicación a la toma de decisiones por su alto nivel de granularidad




Se obtienen los motivos exactos por los cuales cada persona es propensa (compra de producto, concesión de préstamo, fuga de entidad, etc)

Tipologías: global, local y agrupada

EXPLICABILIDAD AGRUPADA

- **Colectiva:** partiendo de la explicabilidad local, se agrupan las observaciones en colectivos con motivos similares
 - + Accionable para decisiones de negocio por comunidad
 - + Número de colectivos parametrizable
 - ⊖ El tamaño de los colectivos no es personalizable
 - ⊖ Agrupación intrínseca por probabilidad



Se obtienen grupos de personas que comparten motivos a la propensión similares

Tipologías: global, local y agrupada

FLUJO ESTÁNDAR PARA EXPLICABILIDAD GLOBAL Y/O LOCAL


Creación y extracción de variables




Preprocesado



Entrenamiento de modelo predictivo




Cálculo de la explicatividad local (Shap values)



Tipologías: global, local y agrupada

FLUJO ESTÁNDAR PARA EXPLICABILIDAD AGRUPADA





¡MUCHAS GRACIAS!

BIG school

BIGSEIO

**GENERAMOS
NEGOCIO**